

Prueba Técnica

Data Scientist (Data) · LLMs

Bienvenida/o al desafío técnico de MercadoLibre. Queremos conocer cómo aboradas un problema real: desde el **diseño de la solución** hasta la **presentación de resultados**. ¡Mucho éxito!

01

Instrucciones generales

El objetivo de esta prueba es conocer **cómo aboradas un problema real** de preparación de datos para aplicaciones de LLMs: desde que entiendes un conjunto de datos crudo y desordenado, hasta que lo conviertes en conjuntos de datos estructurados y confiables. No basta con que estén bien organizados: tienen que estar pensados para entrenar y evaluar un modelo con ellos, con un esquema y una separación de datos que resistan ese uso. No es necesario que llegues con conocimiento previo de catálogo o de MercadoLibre: *lo que evaluamos es la forma en la que te desenvuelves en cada etapa del proceso, no si conoces de antemano la respuesta.*

El uso de asistentes de IA (Claude, ChatGPT, Copilot, etc.) está **permitido y es esperado**, como en el trabajo real.

02

Escenario

Te unes a un equipo que construye flujos de datos para aplicaciones de LLMs. Tenemos una colección de **documentación cruda** exportada de varios proyectos de software: archivos en formato Markdown que vienen de equipos distintos, están desordenados, parcialmente duplicados y con una estructura inconsistente entre sí.

Queremos convertir esa documentación en **conjuntos de datos estructurados** que sirvan como insumo para casos de uso de LLMs: *retrieval*, evaluación, *supervised fine-tuning* (SFT) y *continued pretraining* (CPT).

Tarea

Construir un flujo local que, a partir de la carpeta cruda de documentación, produzca al menos **dos salidas**:

- Un **corpus de texto normalizado** (JSONL), donde cada fila es una unidad de texto normalizada (un documento completo o una porción de él, a tu criterio) con su procedencia, útil para *retrieval* o *CPT*.
- Un **conjunto de preguntas y respuestas** (JSONL): un dataset de Q&A derivado de la documentación, para que un modelo aprenda a responder preguntas sobre ella. Cada fila es un par pregunta-respuesta con su procedencia, útil para *SFT* o evaluación.

Cada fila de salida debe preservar su *procedencia*: identificador de proyecto, archivo fuente, título o ruta de la sección, y la metadata suficiente para rastrearla hasta el origen.

Datos entregados

docs_raw/

Documentación cruda de varios proyectos de software ficticios, en formato Markdown. Tal como llega en la vida real: desordenada, con estructura inconsistente y contenido parcialmente duplicado.

Qué queremos ver

No hay una única respuesta correcta. Nos interesa tu criterio frente a decisiones como estas, más que la solución exacta a la que llegues:

- Cómo organizas y normalizas texto de fuentes heterogéneas.
- Qué es señal y qué es ruido, y cómo lo decides.
- Cómo manejas el contenido duplicado.
- Cómo generas las preguntas y respuestas, y cómo cuidas su calidad.

El **esquema** de tus salidas lo diseñas tú. En las dos salidas, más volumen no es mejor por sí solo: la calidad del corpus y la del set de preguntas y respuestas importan tanto como la cantidad.

Si quieres contexto sobre *fine-tuning* y cómo se ve un dataset para entrenar un modelo, estas guías son una buena referencia (opcional): [Unsloth · FAQ: ¿es fine-tuning para mí?](#) y [Datasets Guide](#).

Entrega

Un **repositorio de GitHub público** que incluya:

- Tu **código**: el flujo completo, reproducible desde cero (dependencias declaradas, sin rutas ni datos locales hardcodedos).
- Los **conjuntos de datos** que produce (el corpus y las preguntas y respuestas).
- Un **README** corto con las decisiones que tomaste y los pasos exactos para instalar dependencias y correr el flujo.
- El **material de tu presentación** para la entrevista (o un enlace a él).

Tu entregable *no* es un modelo entrenado, sino tu código y los conjuntos de datos que produce. No hace falta entrenar ni ajustar ningún modelo para resolver esta prueba. Eso sí: en la entrevista vamos a clonar tu repositorio y correr tu flujo en vivo, así que asegúrate de que funcione en una máquina distinta a la tuya siguiendo solo tu README.

Entrevista (45-60 min)



Empezamos con tu **presentación**: cuentas el problema, tus decisiones y tus resultados. Sigue un **desafío en vivo** en dos partes: trabajamos juntos sobre tu propio código, y después discutimos cómo llevarías los conjuntos de datos que produjiste a un **experimento de entrenamiento**: qué probarías, contra qué lo compararías, y cómo sabrías si funcionó. Y cerramos con un espacio **de preguntas**, no técnico, para conocernos mejor y resolver tus dudas.

Información adicional

Si tienes dudas, contáctanos por los canales que te compartimos junto con esta prueba.

¡Éxitos!

MercadoLibre · AA&ML